

Лабораторная работа №3

Модификации градиентного спуска

Георгий Лаврентьев, Дмитрий Коваль
группа М3232

Май 2026

1 Постановка задачи

В работе исследуются модификации градиентного спуска для задачи безусловной минимизации

$$f(x) \rightarrow \min, \quad f: \mathbb{R}^n \rightarrow \mathbb{R}, \quad f \in C^1(\mathbb{R}^n).$$

Рассматриваются следующие методы:

1. Momentum;
2. Nesterov momentum;
3. AdaGrad;
4. RMSProp;
5. AdaDelta;
6. Adam.

Исследование проводится на:

- хорошо обусловленной квадратичной функции;
- плохо обусловленной квадратичной функции;
- функции Розенброка;
- функции Экли;
- функции Химмельблау.

Критерием остановки является условие

$$\|\nabla f(x_k)\| < 10^{-8}.$$

2 Теоретические сведения

2.1 Общая логика модификаций

Большинство современных модификаций градиентного спуска имеют вид

$$x_{k+1} = x_k - \alpha_k p_k,$$

где направление p_k строится не только по текущему градиенту, но и с использованием внутреннего состояния метода.

Методы можно разделить на две группы:

1. методы с памятью направления: Momentum, Nesterov;
2. адаптивные по координатным методам: AdaGrad, RMSProp, AdaDelta, Adam.

В данной работе рассматривается детерминированная постановка, то есть используется точный градиент

$$g_k = \nabla f(x_k).$$

2.2 Momentum

Метод Momentum задаётся формулами

$$m_{k+1} = \beta m_k + g_k,$$

$$x_{k+1} = x_k - \alpha m_{k+1}.$$

Параметр $\beta \in [0, 1)$ отвечает за силу инерции.

Метод использует сглаженную сумму предыдущих градиентов, что уменьшает поперечные колебания в узких оврагах.

При слишком больших α и β метод может перелетать через минимум, что приводит к расходимости.

2.3 Nesterov

Метод Нестерова:

$$y_k = x_k + \beta(x_k - x_{k-1}),$$

$$x_{k+1} = y_k - \alpha \nabla f(y_k).$$

В отличие от Momentum, градиент вычисляется в предсказанной точке y_k .

Это позволяет раньше замечать изменение геометрии функции и уменьшать излишние колебания траектории.

2.4 AdaGrad

AdaGrad определяется соотношениями

$$G_{k+1} = G_k + g_k^2,$$

$$x_{k+1} = x_k - \alpha \frac{g_k}{\sqrt{G_{k+1}} + \varepsilon}.$$

Метод автоматически уменьшает шаг по координатам с большими градиентами.

Главный недостаток AdaGrad — монотонное накопление G_k , из-за чего шаг со временем стремится к нулю.

2.5 RMSProp

Метод RMSProp:

$$G_{k+1} = \rho G_k + (1 - \rho) g_k^2,$$

$$x_{k+1} = x_k - \alpha \frac{g_k}{\sqrt{G_{k+1}} + \varepsilon}.$$

В отличие от AdaGrad, используется экспоненциальное забывание старой информации.

Параметр ρ задаёт длину памяти метода.

2.6 AdaDelta

AdaDelta определяется формулами

$$G_{k+1} = \rho G_k + (1 - \rho) g_k^2,$$

$$\Delta x_k = -\frac{\sqrt{u_k + \varepsilon}}{\sqrt{G_{k+1}} + \varepsilon} g_k,$$

$$u_{k+1} = \rho u_k + (1 - \rho) (\Delta x_k)^2,$$

$$x_{k+1} = x_k + \Delta x_k.$$

В методе одновременно адаптируются:

- статистика градиентов;
- статистика самих смещений.

2.7 Adam

Метод Adam:

$$m_{k+1} = \beta_1 m_k + (1 - \beta_1) g_k,$$

$$v_{k+1} = \beta_2 v_k + (1 - \beta_2) g_k^2,$$

$$\hat{m}_{k+1} = \frac{m_{k+1}}{1 - \beta_1^{k+1}},$$

$$\hat{v}_{k+1} = \frac{v_{k+1}}{1 - \beta_2^{k+1}},$$

$$x_{k+1} = x_k - \alpha \frac{\hat{m}_{k+1}}{\sqrt{\hat{v}_{k+1} + \varepsilon}}.$$

Adam сочетает идеи Momentum и RMSProp.

3 Тестовые функции

3.1 Квадратичные функции

Хорошо обусловленная функция:

$$f(x, y) = x^2 + y^2.$$

:contentReference[oaicite:0]index=0

Плохо обусловленная функция:

$$g(x, y) = 50x^2 + \frac{1}{2}y^2.$$

:contentReference[oaicite:1]index=1

3.2 Функция Розенброка

$$f(x, y) = (1 - x)^2 + 100(y - x^2)^2.$$

:contentReference[oaicite:2]index=2

3.3 Функция Экли

$$f(x, y) = -20e^{-0.2\sqrt{(x^2+y^2)/2}} - e^{(\cos 2\pi x + \cos 2\pi y)/2} + 20 + e.$$

3.4 Функция Химмельблау

$$f(x, y) = (x^2 + y - 11)^2 + (x + y^2 - 7)^2.$$

4 Исследование параметров

Для каждого метода проводилось исследование зависимости сходимости от параметров.

Для методов с одним параметром использовались line-графики, для методов с двумя параметрами — heatmap.

4.1 AdaGrad




Рис. 1: AdaGrad: зависимость числа итераций от α .

На малых α метод сходится медленно, а на больших α возможны колебания.

Кроме того, на больших числах итераций наблюдается замедление, связанное с накоплением величины

$$G_k = \sum_{t=0}^k g_t^2.$$

Из-за этого эффективный шаг постепенно уменьшается почти до нуля.

4.2 Momentum




Рис. 2: Momentum: heatmap по параметрам (α, β) .

При больших значениях α и β метод становится неустойчивым.

Инерционный член

$$\beta(x_k - x_{k-1})$$

начинает доминировать, из-за чего траектория перелетает через минимум.

На плохо обусловленной функции это особенно заметно: траектория начинает колебаться поперёк узкой долины.

4.3 Adam




Рис. 3: Adam: зависимость сходимости от (β_1, β_2) .

При слишком больших β_1 и β_2 внутренние статистики обновляются слишком медленно. Метод начинает поздно реагировать на изменение геометрии функции, что увеличивает число итераций.

5 Траектории методов

5.1 Квадратичные функции




Рис. 4: Траектории методов на квадратичных функциях.

На плохо обусловленной квадратичной функции обычный градиентный спуск и Momentum демонстрируют выраженные поперечные колебания.

Nesterov корректирует траекторию раньше, поэтому движение оказывается более устойчивым.

5.2 Функция Розенброка




Рис. 5: Траектории на функции Розенброка.

Функция Розенброка содержит узкий изогнутый овраг.

Из-за этого методы с большим шагом часто перелетают через дно оврага и начинают совершать колебания.

Adam и Momentum оказались наиболее устойчивыми.

5.3 Функция Экли




Рис. 6: Траектории на функции Экли.

Функция Экли имеет большое число локальных минимумов.

Траектория существенно зависит от стартовой точки и параметров метода.

5.4 Функция Химмельблау




Рис. 7: Траектории на функции Химмельблау.

На функции Химмельблау методы могут сходиться к различным локальным минимумам.

6 Причины расходимости

Таблица 1: Основные причины неустойчивости методов

Метод	Причина расходимости
Momentum	слишком сильная инерция и перелёты через минимум
Nesterov	слишком агрессивная экстраполяция
AdaGrad	затухание эффективного шага почти до нуля
RMSProp	нестабильное локальное масштабирование
AdaDelta	сложная динамика адаптации числителя и знаменателя
Adam	слишком медленное обновление статистик при больших β_1, β_2

7 Выводы

1. Momentum и Nesterov уменьшают поперечные колебания и ускоряют движение вдоль оврагов.

2. AdaGrad автоматически уменьшает шаг по активным координатам, но может слишком сильно замедляться.
3. RMSProp устраняет главный недостаток AdaGrad за счёт экспоненциального забывания.
4. AdaDelta дополнительно адаптирует масштаб самих смещений, что делает динамику метода более сложной.
5. Adam сочетает идеи Momentum и RMSProp и в большинстве экспериментов показал наиболее устойчивое поведение.
6. На плохо обусловленных и многоэкстремальных функциях результат существенно зависит от параметров метода и стартовой точки.