

Лабораторная работа №3

Модификации градиентного спуска

Георгий Лаврентьев, Дмитрий Коваль
группа М3232

Май 2026

1 Постановка задачи

В работе исследуются модификации градиентного спуска для задачи безусловной минимизации

$$f(x) \rightarrow \min, \quad f : \mathbb{R}^n \rightarrow \mathbb{R}, \quad f \in C^1(\mathbb{R}^n).$$

Рассматриваются следующие методы:

1. Momentum;
2. Nesterov momentum;
3. AdaGrad;
4. RMSProp;
5. AdaDelta;
6. Adam.

Исследование проводится на:

- хорошо обусловленной квадратичной функции;
- плохо обусловленной квадратичной функции;
- функции Розенброка;
- функции Экли;
- функции Химмельблау.

Критерием остановки является условие

$$\|\nabla f(x_k)\| < 10^{-8}.$$

2 Теоретические сведения

2.1 Общая логика модификаций

Большинство современных модификаций градиентного спуска имеют вид

$$x_{k+1} = x_k - \alpha_k p_k,$$

где направление p_k строится не только по текущему градиенту, но и с использованием внутреннего состояния метода.

Методы можно разделить на две группы:

1. методы с памятью направления: Momentum, Nesterov;
2. адаптивные по координатным методам: AdaGrad, RMSProp, AdaDelta, Adam.

В данной работе рассматривается детерминированная постановка, то есть используется точный градиент

$$g_k = \nabla f(x_k).$$

2.2 Momentum

Метод Momentum задаётся формулами

$$m_{k+1} = \beta m_k + g_k, \quad x_{k+1} = x_k - \alpha m_{k+1}.$$

Параметр $\beta \in [0, 1)$ отвечает за силу инерции. Метод использует сглаженную сумму предыдущих градиентов, что уменьшает поперечные колебания в узких оврагах. При слишком больших α и β метод может перелетать через минимум, что приводит к расходимости.

2.3 Nesterov

Метод Нестерова:

$$y_k = x_k + \beta(x_k - x_{k-1}), \quad x_{k+1} = y_k - \alpha \nabla f(y_k).$$

В отличие от Momentum, градиент вычисляется в предсказанной точке y_k . Это позволяет раньше замечать изменение геометрии функции и уменьшать излишние колебания траектории.

2.4 AdaGrad

AdaGrad определяется соотношениями

$$G_{k+1} = G_k + g_k^2, \quad x_{k+1} = x_k - \alpha \frac{g_k}{\sqrt{G_{k+1}} + \varepsilon}.$$

Метод автоматически уменьшает шаг по координатам с большими градиентами. Главный недостаток AdaGrad — монотонное накопление G_k , из-за чего шаг со временем стремится к нулю.

2.5 RMSProp

Метод RMSProp:

$$G_{k+1} = \rho G_k + (1 - \rho)g_k^2, \quad x_{k+1} = x_k - \alpha \frac{g_k}{\sqrt{G_{k+1}} + \varepsilon}.$$

В отличие от AdaGrad, используется экспоненциальное забывание старой информации. Параметр ρ задаёт длину памяти метода.

2.6 AdaDelta

AdaDelta определяется формулами

$$G_{k+1} = \rho G_k + (1 - \rho)g_k^2, \quad \Delta x_k = -\frac{\sqrt{u_k + \varepsilon}}{\sqrt{G_{k+1}} + \varepsilon}g_k, \\ u_{k+1} = \rho u_k + (1 - \rho)(\Delta x_k)^2, \quad x_{k+1} = x_k + \Delta x_k.$$

В методе одновременно адаптируются статистика градиентов и статистика самих смещений. В отличие от RMSProp, явный шаг α отсутствует: его роль берёт на себя отношение двух RMS-величин.

2.7 Adam

Метод Adam:

$$m_{k+1} = \beta_1 m_k + (1 - \beta_1)g_k, \quad v_{k+1} = \beta_2 v_k + (1 - \beta_2)g_k^2, \\ \hat{m}_{k+1} = \frac{m_{k+1}}{1 - \beta_1^{k+1}}, \quad \hat{v}_{k+1} = \frac{v_{k+1}}{1 - \beta_2^{k+1}}, \quad x_{k+1} = x_k - \alpha \frac{\hat{m}_{k+1}}{\sqrt{\hat{v}_{k+1}} + \varepsilon}.$$

Adam сочетает идеи Momentum и RMSProp. Поправки на смещение $\hat{m}_{k+1}$ и $\hat{v}_{k+1}$ компенсируют систематическое занижение на первых итерациях из-за нулевой инициализации $m_0 = v_0 = 0$.

3 Тестовые функции

3.1 Квадратичные функции

Хорошо обусловленная функция ($\kappa = 1$):

$$f(x, y) = x^2 + y^2.$$

Плохо обусловленная функция ($\kappa = 100$):

$$g(x, y) = 50x^2 + \frac{1}{2}y^2.$$

3.2 Функция Розенброка

$$f(x, y) = (1 - x)^2 + 100(y - x^2)^2, \quad x^* = (1, 1), \quad f(x^*) = 0.$$

3.3 Функция Экли

$$f(x, y) = -20e^{-0.2\sqrt{(x^2+y^2)/2}} - e^{(\cos 2\pi x + \cos 2\pi y)/2} + 20 + e, \quad x^* = (0, 0), \quad f(x^*) = 0.$$

3.4 Функция Химмельблау


$$f(x, y) = (x^2 + y - 11)^2 + (x + y^2 - 7)^2.$$

Четыре равнозначных глобальных минимума: $(3, 2)$, $(-2.805, 3.131)$, $(-3.779, -3.283)$, $(3.584, -1.848)$.


4 Исследование параметров на квадратичных функциях

Для каждого метода проводилось исследование зависимости числа итераций от параметров при фиксированной стартовой точке $x_0 = (2, 2)$. Для методов с одним параметром используются line-графики, для методов с двумя параметрами — heatmap.

4.1 AdaGrad



(a) $\kappa = 1$



(b) $\kappa = 100$

Рис. 1: AdaGrad: зависимость числа итераций от α .

Таблица 1: AdaGrad: число итераций от α ($\kappa = 1$ / $\kappa = 100$).

α	Итерации ($\kappa = 1$)	Итерации ($\kappa = 100$)
0.01	—(не сошлось)	—(не сошлось)
0.05	8417	9941
0.1	2232	2636
0.2	617	728
0.5	122	143

На малых α метод сходится медленно, а на больших α число итераций уменьшается. Кроме того, наблюдается замедление из-за накопления $G_k = \sum_{t=0}^k g_t^2$: эффективный шаг постепенно уменьшается почти до нуля.

4.2 AdaDelta




Рис. 2: AdaDelta: зависимость числа итераций от ρ .

Таблица 2: AdaDelta: число итераций от ρ ($\kappa = 1$ / $\kappa = 100$).

ρ	Итерации ($\kappa = 1$)	Итерации ($\kappa = 100$)
0.70	438	—(не сошлось)
0.80	516	518
0.90	656	659
0.95	794	801
0.99	1186	1223

С ростом ρ метод становится более инерционным: память о прошлых обновлениях сохраняется дольше, из-за чего число итераций увеличивается. При $\rho = 0.7$ на плохо обусловленной функции метод не сходится из-за слишком агрессивных шагов.

4.3 Momentum




Рис. 3: Momentum: heatmap числа итераций по параметрам (α, β) .

Таблица 3: Momentum: число итераций ($\kappa = 1$ / $\kappa = 100$). Прочерк — не сошлось.

$\beta \backslash \alpha$	0.001	0.003	0.005	0.01	0.02
$\kappa = 1$					
0.50	3466	1233	756	383	185
0.70	2131	736	437	196	97
0.85	1046	257	191	178	179
0.90	605	263	284	231	299
0.95	504	465	544	489	436
$\kappa = 100$					
0.50	6435	2315	1432	740	375
0.70	3992	1415	863	428	193
0.85	2039	666	354	216	206
0.90	1319	316	310	336	279
0.95	619	634	654	656	664

При больших значениях α и β метод становится неустойчивым: инерционный член $\beta(x_k - x_{k-1})$ начинает доминировать, из-за чего траектория перелетает через минимум. На плохо обусловленной функции это особенно заметно: траектория начинает колебаться поперёк узкой долины.

4.4 Nesterov




Рис. 4: Nesterov: heatmap числа итераций по параметрам (α, β) .

Таблица 4: Nesterov: число итераций ($\kappa = 1$ / $\kappa = 100$). Прочерк — не сошлось.

$\beta \backslash \alpha$	0.001	0.003	0.005	0.01	0.02
$\kappa = 1$					
0.50	3299	1182	729	373	186
0.70	1960	687	413	194	84
0.85	922	251	148	152	129
0.90	525	150	208	204	170
0.95	400	411	375	349	275
$\kappa = 100$					
0.50	6094	2206	1369	712	—
0.70	3639	1304	801	404	—
0.85	1770	591	324	148	—
0.90	1115	188	183	208	—
0.95	306	366	362	375	—

Nesterov в целом сходится быстрее Momentum при тех же параметрах, особенно на хорошо обусловленной функции. На $\kappa = 100$ при $\alpha = 0.02$ метод расходится при всех значениях β : агрессивная экстраполяция перебрасывает итерацию через долину.

4.5 RMSProp




Рис. 5: RMSProp: heatmap числа итераций по параметрам (α, ρ) .

Таблица 5: RMSProp: число итераций ($\kappa = 1$ / $\kappa = 100$). Прочерк — не сошлось.

$\rho \backslash \alpha$	0.001	0.003	0.005	0.01	0.02
$\kappa = 1$					
0.70	—	—	—	—	—
0.80	2036	698	430	227	125
0.90	2076	733	463	257	150
0.95	2146	794	518	305	190
0.99	2583	1139	805	488	260
$\kappa = 100$					
0.70	2021	—	—	—	—
0.80	2033	696	427	224	121
0.90	2069	727	456	250	144
0.95	2133	781	505	292	177
0.99	2517	1075	743	430	212

При малом ρ ($= 0.7$) метод нестабилен на $\kappa = 1$: быстрое забывание приводит к слишком агрессивному масштабированию. С ростом ρ и α число итераций убывает, однако слишком большой ρ ($= 0.99$) замедляет адаптацию.

4.6 Adam




Рис. 6: Adam: heatmap числа итераций по параметрам (β_1, β_2) , $\alpha = 0.05$.

Таблица 6: Adam: число итераций ($\kappa = 1$ / $\kappa = 100$). Прочерк — не сошлось.

$\beta_2 \backslash \beta_1$	0.7	0.8	0.9	0.95	0.99
$\kappa = 1$					
0.900	—	—	—	—	—
0.950	153	192	20476	—	—
0.990	178	186	345	709	28304
0.995	184	180	322	615	3157
0.999	216	199	353	630	2711
$\kappa = 100$					
0.900	—	—	—	—	—
0.950	168	235	—	—	—
0.990	200	227	378	851	—
0.995	214	232	413	774	3157
0.999	230	231	410	817	3040

При слишком больших β_1 и β_2 внутренние статистики обновляются слишком медленно. Метод начинает поздно реагировать на изменение геометрии функции, что увеличивает число итераций. Стандартный выбор $\beta_1 = 0.9$, $\beta_2 = 0.999$ работает хорошо на обеих функциях.

5 Траектории методов на квадратичных функциях

Для каждого метода выбран один набор параметров, обеспечивающий сходимость за разумное число итераций.

Таблица 7: Параметры методов для визуализации траекторий.

Метод	Параметры	Итерации ($\kappa = 1$ / $\kappa = 100$)
Momentum	$\alpha = 0.01, \beta = 0.9$	231 / 336
Nesterov	$\alpha = 0.01, \beta = 0.9$	204 / 208
AdaGrad	$\alpha = 0.2$	617 / 728
RMSProp	$\alpha = 0.01, \rho = 0.9$	257 / 250
AdaDelta	$\rho = 0.95$	794 / 801
Adam	$\alpha = 0.05, \beta_1 = 0.9, \beta_2 = 0.999$	353 / 410




Рис. 7: Траектории методов на квадратичных функциях.

На плохо обусловленной квадратичной функции Momentum демонстрирует выраженные поперечные колебания. Nesterov корректирует траекторию раньше, поэтому движение оказывается более устойчивым. Адаптивные методы (AdaGrad, RMSProp, Adam) эффективно масштабируют шаг по координатам и двигаются более прямолинейно.

6 Исследование сложных функций

6.1 Чувствительность к параметрам

Для каждого метода выбраны три набора параметров. Стартовая точка: $x_0 = (-1, 1)$.

Таблица 8: Сложные функции: чувствительность методов к параметрам. Прочерк — не сошлось.

Метод	Набор	Параметры	Итерации	
			Розенброк	Химмельблау
Momentum	set1	$\alpha = 0.001, \beta = 0.8$	6007	168
Momentum	set2	$\alpha = 0.003, \beta = 0.9$	988	324
Momentum	set3	$\alpha = 0.001, \beta = 0.9$	3077	338
Nesterov	set1	$\alpha = 0.001, \beta = 0.8$	5214	116
Nesterov	set2	$\alpha = 0.001, \beta = 0.9$	2526	213
Nesterov	set3	$\alpha = 0.0005, \beta = 0.9$	4816	229
AdaGrad	set1	$\alpha = 0.05$	37442	12331
AdaGrad	set2	$\alpha = 0.1$	26142	3141
AdaGrad	set3	$\alpha = 0.2$	22423	813
RMSProp	set1	$\alpha = 0.02, \rho = 0.9$	—	184
RMSProp	set2	$\alpha = 0.05, \rho = 0.9$	—	90
RMSProp	set3	$\alpha = 0.01, \rho = 0.95$	—	371
AdaDelta	set1	$\rho = 0.99$	—	1000
AdaDelta	set2	$\rho = 0.999$	—	620
AdaDelta	set3	$\rho = 0.95$	—	—
Adam	set1	$\alpha = 0.01, \beta_1 = 0.85, \beta_2 = 0.99$	—	631
Adam	set2	$\alpha = 0.02, \beta_1 = 0.9, \beta_2 = 0.999$	1314	552
Adam	set3	$\alpha = 0.05, \beta_1 = 0.9, \beta_2 = 0.999$	1233	442

Таблица 9: Сложные функции: чувствительность методов к параметрам (функция Экли). Прочерк — не сошлось.

Метод	Набор	Параметры	Итерации (Экли)
Momentum	set1	$\alpha = 0.001, \beta = 0.8$	159
Momentum	set2	$\alpha = 0.003, \beta = 0.9$	311
Momentum	set3	$\alpha = 0.001, \beta = 0.9$	301
Nesterov	set1	$\alpha = 0.001, \beta = 0.8$	120
Nesterov	set2	$\alpha = 0.001, \beta = 0.9$	194
Nesterov	set3	$\alpha = 0.0005, \beta = 0.9$	222
AdaGrad	set1	$\alpha = 0.05$	1047
AdaGrad	set2	$\alpha = 0.1$	54
AdaGrad	set3	$\alpha = 0.2$	51
RMSProp	set1	$\alpha = 0.02, \rho = 0.9$	—
RMSProp	set2	$\alpha = 0.05, \rho = 0.9$	—
RMSProp	set3	$\alpha = 0.01, \rho = 0.95$	—
AdaDelta	set1	$\rho = 0.99$	105
AdaDelta	set2	$\rho = 0.999$	68
AdaDelta	set3	$\rho = 0.95$	—
Adam	set1	$\alpha = 0.01, \beta_1 = 0.85, \beta_2 = 0.99$	257
Adam	set2	$\alpha = 0.02, \beta_1 = 0.9, \beta_2 = 0.999$	378
Adam	set3	$\alpha = 0.05, \beta_1 = 0.9, \beta_2 = 0.999$	359

Функция Розенброка оказалась наиболее сложной: RMSProp, AdaDelta и Adam (set1) не сошлись из-за нестабильности в узком изогнутом овраге. На функции Экли RMSProp

также нестабилен, тогда как AdaDelta (set1, set2) сходится. Химмельблау — наиболее «лёгкая» из сложных функций: большинство методов сходятся во всех конфигурациях.

6.2 Траектории из нескольких стартовых точек

Для каждой функции выбраны 2–3 стартовые точки и один набор параметров для каждого метода.




Рис. 8: Траектории на функции Розенброка (3 стартовые точки: $(-1, 1)$, $(0.5, -0.5)$, $(-1.5, 2)$).

Функция Розенброка содержит узкий изогнутый овраг. Из-за этого RMSProp и AdaDelta расходятся, тогда как Momentum и Adam оказались наиболее устойчивыми. AdaGrad требует значительно больше итераций из-за монотонного затухания шага.




Рис. 9: Траектории на функции Экли (3 стартовые точки: $(1.5, 1)$, $(-2, 2)$, $(2.5, -1.5)$).

Функция Экли имеет большое число локальных минимумов. Траектория существенно зависит от стартовой точки: из разных точек методы сходятся к разным локальным минимумам. RMSProp нестабилен при большинстве стартовых точек.




Рис. 10: Траектории на функции Химмельблау (3 стартовые точки: $(0, 0)$, $(-3, 3)$, $(3, -1)$).

На функции Химмельблау методы могут сходиться к различным локальным минимумам в зависимости от стартовой точки.

7 Причины расходимости

Таблица 10: Основные причины неустойчивости методов.

Метод	Причина расходимости
Momentum	Слишком сильная инерция при больших α и β : инерционный член $\beta(x_k - x_{k-1})$ начинает доминировать и траектория перелетает через минимум.
Nesterov	Слишком агрессивная экстраполяция при больших α : предсказанная точка y_k попадает в зону с большим градиентом и происходит расходимость.
AdaGrad	Монотонное накопление G_k приводит к тому, что эффективный шаг затухает почти до нуля, и метод фактически останавливается.
RMSProp	При малом ρ адаптация слишком агрессивна: нестабильное локальное масштабирование приводит к осцилляциям на сложных функциях.
AdaDelta	Сложная динамика адаптации одновременно числителя и знаменателя шага делает метод чувствительным к локальным изменениям траектории.
Adam	Слишком медленное обновление статистик при больших β_1, β_2 : метод поздно реагирует на изменение геометрии функции.

8 Выводы

1. Momentum и Nesterov уменьшают поперечные колебания и ускоряют движение вдоль оврагов. Nesterov в большинстве случаев сходится быстрее Momentum за счёт предсказывающей экстраполяции.
2. AdaGrad автоматически уменьшает шаг по активным координатам, но может слишком сильно замедляться из-за монотонного накопления G_k .
3. RMSProp устраняет главный недостаток AdaGrad за счёт экспоненциального забывания, однако на сложных функциях (Розенброк, Экли) оказался нестабилен.
4. AdaDelta дополнительно адаптирует масштаб самих смещений, что делает динамику метода более сложной и чувствительной к параметру ρ .
5. Adam сочетает идеи Momentum и RMSProp и в большинстве экспериментов показал наиболее устойчивое поведение.
6. На плохо обусловленных и многоэкстремальных функциях результат существенно зависит от параметров метода и стартовой точки.
7. Функция Розенброка оказалась наиболее сложной для всех методов: RMSProp и AdaDelta не смогли сойтись при выбранных параметрах.